

大模型推理科研实践日程安排

第一阶段：学术报告（7.15-7.16）

日期	时间	报告	腾讯会议
7.15	14:00-14:30	大模型推理性能优化概述	341-252-035
	14:30-15:30	报告 1：端云投机加速 LLM 推理 ——异构并行与 DFlash 优化研究	
	15:30-16:30	报告 2：面向生成式推荐模型的多芯异构推理调度优化	
7.16	9:30-10:30	报告 3：面向多阶段智能体回溯推理加速的上下文优化研究	548-685-977
	10:30-11:30	报告 4：GUI/CUA Agents 环境、轨迹与强化学习	

注：进入腾讯会议后显示名称请设定为“姓名-学校-专业”

第二阶段：科研实践（7.17-7.30）

每个学术报告之后会有相关论文阅读或系统实践安排，请根据自己的兴趣和基础选择其中 1-2 个细分方向阅读相关论文资料或部署系统实践。期间可以和报告的研究生同学联系进行一些讨论，但以自己开展为主。

第三阶段：总结报告（7.31）

线上总结报告，请准备 ppt 简要报告此次实践进展，不超过 10 分钟报告，严格计时。总结报告建议要点：

1. 基于阅读的论文和系统实践，自拟标题，就某个研究问题或某个关键技术点展开。
2. 基本内容框架的建议结构，可根据内容自行调整和取舍。
 - 1) 报告标题：准确表达报告内容，避免过于宽泛，可参考第一阶段学术报告标题。
 - 2) 研究背景：描述研究问题的来源、目标、意义、难点等。
 - 3) 进展综述：描述当前相关研究工作，围绕阅读的论文和相关资料展开，不要仅仅罗列，根据自己理解总结。
 - 4) 后续工作：根据当前进展等提一些自己对该问题的想法和后续可能做的研究工作，聚焦而不要宽泛，尽可能说明动机或理由。

附录：学术报告简介

报告 1：端云投机加速 LLM 推理——异构并行与 DFlash 优化研究

报告人：朱英杰

摘要：面向用户服务的 LLM 推理系统对时延极为敏感，投机推理（Speculative Decoding）通过轻量级草稿模型预猜多个未来 token、大模型一次验证，在无损质量的前提下显著加速生成。然而，不同部署场景下的草稿策略与效率瓶颈差异显著，需针对性优化。端侧设备上，独立小模型的草稿时延接近验证时间，成为主要瓶颈。我们提出异构并行投机方案，利用 AICPU 等异构算力，在大模型验证阶段并行执行下一轮草稿生成，将草稿时延隐藏于验证过程，有效提升端到端生成速度。云侧场景中，DFlash 通过块并行解码一次生成多个 token，较传统基于大模型隐藏层信息的 MTP 方法在速度和精度上均有优势，但因其打破因果依赖导致接受率波动大且需大规模训练，线上部署面临挑战。我们围绕 DFlash 及 Domino、DSpark 等改进方案，从模型结构与推理部署多维度评估，探讨了实际应用中的方案设计。两项工作共同探索投机推理在 LLM 系统中的实际效能，为高效推理服务提供实践依据与技术参考。

报告 2：面向生成式推荐模型的多芯异构推理调度优化

报告人：汪淑兰

摘要：随着生成式推荐模型在参数规模与结构复杂性上的持续膨胀，单卡推理已难以在严格的 SLA 下满足时延要求，多卡异构集群成为支撑在线推荐系统的必然基础设施。然而，集群中通常混合不同代际的设备，其算力与芯间带宽差异显著，加之推荐请求的输入序列长度范围宽广且呈现时变的重尾分布，导致各并行策略在不同长度下的推理性能悬殊。本报告介绍面向集群的轻量级在线自适应推理调度框架，平衡单个请求的推理延迟与系统整体吞吐量。

报告 3：面向多阶段智能体回溯推理加速的上下文优化研究

报告人：李杨

摘要：多阶段智能体在处理复杂任务时，通常会按照预设流程逐步执行，并不断累积历史上下文。当后续阶段的分析结果需要返回给前序阶段进行修正或补充时，

直接重放完整历史容易造成上下文过长、目标模型窗口受限以及推理延迟增加。研究将阶段输出拆分为完整内容、摘要、结论、结构化字段和证据索引等不同粒度的信息表示，当回溯到不同目标阶段时，根据剩余上下文窗口、SLO 等约束选择不同粒度进行传输，实现轻量化传递和局部上下文穿透。

报告 4: GUI/CUA Agents 环境、轨迹与强化学习

报告人: 王泽洲

摘要: 大模型智能体正在从文本问答走向真实软件操作，但 GUI/CUA scaling 的瓶颈不再只是 policy 能否看懂屏幕和点对按钮，而是缺少可持续供给的交互世界：真实软件难以 reset 和安全 rollout，离线轨迹不能提供动作后果，手工环境又难以规模化。本报告围绕这一瓶颈，系统介绍 GUI/CUA agents 的任务形式化、observation/action space、evaluation protocol，以及从 GUI traces、真实执行 benchmark、可控环境到 policy/RL 的研究脉络。随后报告介绍三项相关工作：InfiniteWeb 展示给定 spec 时可验证环境可以规模化生成；BEPa 将 expert traces 同化为更稳定的 on-policy RL 信号；Trace2World 进一步探索从真实 trace pool 归纳 RL World Spec。报告的核心观点是，GUI/CUA 的下一阶段进展将取决于可验证、可重置、可训练的 environment supply。